

MapReduce vs Spark

El objetivo de este documento es analizar las diferencias en la complejidad de implementación entre ambas soluciones. Nos centramos principalmente en la abstracción, la mantenibilidad del código y el esfuerzo mental requerido.

MapReduce: Tuvimos que adaptar nuestra lógica a la estructura del paradigma. Para resolver problemas de múltiples pasos, tuvimos que hacer uso de múltiples Jobs, lo cual aumentó la dificultad y nos obligó a llevar un control manual muy estricto de los datos que pasaban de una etapa a otra.

Spark: Fue más sencillo enfocarse en la solución, ya que Spark resuelve mucho de la lógica interna, por lo que, solo tuvimos que definir qué hacer y no tanto cómo hacerlo. Esto redujo bastante la complejidad de la programación. Notamos también que la legibilidad del código es mejor y el mantenimiento más simple, ya que cometimos menos errores y necesitamos muchas menos líneas de código para resolver lo mismo.

Conclusión

La diferencia fundamental estuvo en la lógica del desarrollo. En el TP1, gran parte del esfuerzo mental se fue en entender cómo forzar el problema para que encaje en el modelo MapReduce. En el TP2, el esfuerzo se centró casi exclusivamente en la lógica detrás, dejando que el framework se ocupe de la ejecución.